

1. Valószínűségi változó fogalma

Formálisan az $X : \Omega \rightarrow \mathbb{R}$ függvényt nevezzük valószínűségi változónak.

5.5 Definíció $\xi : \Omega \rightarrow \mathbb{R}$ valószínűségi változó, ha minden $x \in \mathbb{R}$ számra $\{\omega : \xi(\omega) < x\} \in \mathcal{A}$.

5.6 Definíció A ξ valószínűségi változó **diszkrét**, ha értékkészlete véges vagy megszámlálható, azaz léteznek olyan x_k valós számok és A_k teljes eseményrendszer, hogy $\xi = \sum_k x_k \cdot \chi_{A_k}$.

2. Teljes valószínűség tétele

Legyenek A_1, \dots, A_n események. Akkor mondjuk, hogy teljes eseményrendszert alkotnak, ha:

1. páronként egymást kizárják;
2. egyesítésük az Ω (biztos esemény)

3. Mikor független két esemény?

Az A és B esemény független, ha $P(A \cap B) = P(A) \cdot P(B)$, ami éppen azt jelenti, hogy $P(A|B) = P(A)$ (ha a feltételes valószínűség értelmes, azaz $P(A) > 0$).

4. Binomiális tétel

Ha a és b tetszőleges valós számok és n pozitív egész szám, akkor:

$$(a+b)^n = \binom{n}{0}a^n + \binom{n}{1}a^{n-1}b^1 + \dots + \binom{n}{i}a^{n-i}b^i + \dots + \binom{n}{n-1}ab^{n-1} + \binom{n}{n}b^n.$$

A binomiális tétel rövidebb alakja:

$$(a+b)^n = \sum_{i=0}^n \binom{n}{i} a^{n-i} b^i$$

5. Valószínűségi változók függvényének várható értékét diszkrét és folytonos esetre is

A $p_i = P(X=x_i)$ eloszlással megadott valószínűségi változó várható értéke $E(X) := p_1x_1 + p_2x_2 + \dots$, ha a sor abszolút konvergens.

5.11 Definíció $E\xi = \int_{\mathbb{R}} x dF_{\xi}(x)$ és $Eg(\xi) = \int_{\mathbb{R}} g(x) dF_{\xi}(x)$, ahol a $dF_{\xi}(x)$ szerinti integrálás a Lebesgue-Stieltjes-integrálást jelöli, ha $\int_{\mathbb{R}} |x| dF_{\xi}(x)$ illetve $\int_{\mathbb{R}} |g(x)| dF_{\xi}(x)$ véges.

Abszolút folytonos esetben a várható érték a sűrűségfüggvény segítségével határozható meg. $E\xi = \int_{\mathbb{R}} x \cdot f_{\xi}(x) dx$ és $Eg(\xi) = \int_{\mathbb{R}} g(x) \cdot f_{\xi}(x) dx$.

A következő példában a legnevezetesebb abszolút folytonos eloszlású valószínűségi változók várható értékét határozzuk meg.

6. Maximum-likelihood módszer

A maximum likelihood módszer célja, hogy adott mérési értékekhez, az ismeretlen paramétereknek olyan becslését adja meg, amely mellett az adott érték a legnagyobb valószínűséggel következik be. Az eljárás a *likelihood függvény* maximalizálásával történik.

A maximum likelihood becslés azokban az esetekben használatos amikor az egyes mérési eredmények olyan véletlen eseményekként interpretálhatóak, amelyek egy vagy több ismeretlen paramétertől függenek. Mivel a vizsgált értékek kizárólagosan az ismeretlen paraméter(ek)től függenek, előállíthatók ezen paraméter vagy paraméterek függvényeként. A mérést, becslést végző kutató ezt a paramétert határozza meg, így maximalizálja a mért minta által követett valószínűséget.

A maximum likelihood módszer egy X valószínűségi változóból indul ki, amelynek a sűrűség- vagy tömegfüggvénye f és q paramétertől függ.

7. Likelihood függvény folytonos és diszkrét eloszlásra is

8. Egy valószínűségi változó χ^2 -eloszlású

22.2. definíció: Legyenek X_1, X_2, \dots, X_n független, standard normális eloszlású valószínűségi változók. Ekkor a belőlük képzett

$$\chi_n^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

valószínűségi változó eloszlását n szabadsági fokú χ^2 (khi négyzet)-eloszlásnak nevezzük.

Az n szabadsági fokú χ^2 -eloszlás sűrűségfüggvénye:

$$f_n(x) = \begin{cases} \frac{x^{\frac{n}{2}-1} \cdot e^{-\frac{x}{2}}}{2^{\frac{n}{2}} \cdot \Gamma(\frac{n}{2})} & \text{ha } x > 0, \\ 0 & \text{ha } x \leq 0. \end{cases}$$

Az n szabadsági fokú χ^2 -eloszlású valószínűségi változó várható értéke és szórásnégyzete:

$$E(\chi_n^2) = n \quad \text{és} \quad D^2(\chi_n^2) = 2n.$$

9. Valószínűségi változó t -eloszlású

A Student-eloszlás (vagy másnéven t -eloszlás) adja a matematikai statisztikában használatos t -próba alapját.

22.3. definíció: Legyenek Y és X_1, X_2, \dots, X_n független, standard normális eloszlású valószínűségi változók. Ekkor a belőlük képzett

$$t_n = \frac{Y}{\sqrt{\frac{X_1^2 + X_2^2 + \dots + X_n^2}{n}}}$$

valószínűségi változó eloszlását n szabadsági fokú Student-eloszlásnak (t -eloszlásnak) nevezzük.

Az n szabadsági fokú t -eloszlás sűrűségfüggvénye:

$$f(x) = \frac{1}{\sqrt{n\pi}} \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})} \frac{1}{\left(1 + \frac{x^2}{n}\right)^{\frac{n+1}{2}}}.$$

Az n szabadsági fokú t -eloszlású valószínűségi változó várható értéke:

$$E(t_n) = \begin{cases} 0 & \text{ha } n \geq 2, \\ \text{nem létezik} & \text{ha } n = 1. \end{cases}$$

Szórásnégyzete:

$$D^2(t_n) = \begin{cases} \frac{n}{n-2} & \text{ha } n \geq 3, \\ \text{nem létezik} & \text{ha } n = 1, 2. \end{cases}$$

10. Fisher-tétel

11. Konfidencia-intervallum

23.12. definíció: A (c_1, c_2) intervallumot az X valószínűségi változó α paraméterére vonatkozó $(1 - \varepsilon) \cdot 100\%$ megbízhatósági szintű konfidencia-intervalumnak nevezzük, ha

$$P(c_1 < \alpha < c_2) = 1 - \varepsilon$$

teljesül.

12. Normális eloszlású minta konfidenciaintervalluma a várható értékre és a szórásnégyzetre.

13. Valószínűségi vektorváltozó és legfontosabb tulajdonságai

- Emlékeztető: $X = (X_1, X_2, \dots, X_d): \Omega \rightarrow \mathbb{R}^d$ függvény valószínűségi vektorváltozó, ha $\{\omega: X(\omega) \in B\} \in \mathcal{A}$ minden B d -dimenziós Borel halmazra. (Pontosan akkor teljesül, ha X_j valószínűségi változó minden $1 \leq j \leq d$ -re.)
- $Q_X(B) := P\{\omega: X(\omega) \in B\}$ az X eloszlása \mathbb{R}^d Borel-halmazain.
- Az $F_X(z) := P(X \leq z)$ $\mathbb{R}^d \rightarrow \mathbb{R}$ függvény az X valószínűségi vektorváltozó együttes eloszlásfüggvénye.
- Az egydimenziós esettel analóg tulajdonságai:
 - $0 \leq F_X(z) \leq 1$
 - $F_X(z)$ minden koordinátájában monoton növekvő
 - $\lim_{z_j \rightarrow \infty} F_X(z) = 1$, ha z minden koordinátájára $z_j \rightarrow \infty$
 - $\lim_{z_j \rightarrow -\infty} F_X(z) = 0$ ha z legalább egy koordinátájára $z_j \rightarrow -\infty$
 - $F_X(z)$ minden koordinátájában balról folytonos.

14. Valószínűségi mező fogalma

3.1. definíció: Ha egy kísérlettel kapcsolatban az elemi események száma véges (n), és minden elemi esemény valószínűsége egyenlő ($\frac{1}{n}$), akkor a k féleképpen bekövetkező A esemény valószínűsége

$$P(A) = \frac{\text{kedvező esetek száma}}{\text{összes eset száma}} = \frac{k}{n}.$$

Ebben az esetben azt mondjuk, hogy az események és ezek valószínűségei klasszikus valószínűségi mezőt alkotnak.

15. Becslések aszimptotikus torzítatlansága

16. t-próba egy- és kétmintás esetre is

Legyen $X \sim \mathcal{N}(m, \sigma^2)$ eloszlású valószínűségi változó, ahol az m várható érték és a σ szórás ismeretlenek. Az X valószínűségi változóra vonatkozó n elemű minta X_1, X_2, \dots, X_n . A próba szintje $1 - \alpha$. A hipotézis a várható értékre vonatkozik:

$$\begin{aligned} H_0 &: m = m_0 \\ H_1 &: m \neq m_0 \text{ (kétoldali eset)}. \end{aligned}$$

Ismert, hogy $\frac{\bar{X} - m}{s_n^*} \sqrt{n}$ valószínűségi változó $(n-1)$ paraméterű t (Student)-eloszlású, ahol

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

és

$$s_n^{*2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Tehát ha a nullhipotézis igaz, a

$$t = \frac{\bar{X} - m_0}{s_n^*} \sqrt{n}$$

A

próbat statisztika $(n - 1)$ paraméterű t -eloszlású. Az $(n - 1)$ paraméterű t -eloszlás táblázatából kiolvasható az a $t_{n-1}(\alpha/2)$ kritikus érték, amelyre

$$P(t_{n-1} \geq t_{n-1}(\alpha/2)) = \frac{\alpha}{2}$$

fennáll. Erre az értékre igaz, hogy

$$P(-t_{n-1}(\alpha/2) < t_{n-1} < t_{n-1}(\alpha/2)) = 1 - \alpha.$$

A kritikus tartomány tehát:

$$C_1 = \left\{ (x_1, \dots, x_n) : |t| \geq t_{n-1} \left(\frac{\alpha}{2} \right) \right\}$$

és az elfogadási tartomány:

$$C_0 = \left\{ (x_1, \dots, x_n) : |t| < t_{n-1} \left(\frac{\alpha}{2} \right) \right\}.$$

Egyoldali esetben az ellenhipotézis

$$H_1 : m > m_0 \text{ (vagy } m < m_0) \text{ alakú.}$$

Ekkor azt a $t_{n-1}(\alpha)$ értéket kell kikeresnünk a táblázatból, amely a következő összefüggést teljesíti:

$$\begin{aligned} \mathbb{P}(t_{n-1} \geq t_{n-1}(\alpha)) &= \alpha \\ \text{(vagy } \mathbb{P}(t_{n-1} \leq -t_{n-1}(\alpha)) &= \alpha). \end{aligned}$$

Az egyoldali ellenhipotézishez tartozó kritikus tartomány:

$$\begin{aligned} C_1 &= \{ (x_1, \dots, x_n) : t \geq t_{n-1}(\alpha) \} \\ \text{(vagy } C_1 &= \{ (x_1, \dots, x_n) : t \leq -t_{n-1}(\alpha) \} \}. \end{aligned}$$

A kétmintás t -próba azt vizsgálja, hogy két külön mintában egy-egy valószínűségi változó átlagai egymástól szignifikánsan különböznek-e.

H_0 : Az X és Y valószínűségi változók várható értékei megegyeznek ($E(X) = E(Y)$)

H_1 : Az X és Y valószínűségi változók várható értékei nem egyeznek meg ($E(X) \neq E(Y)$)

Próbat statisztika:

$$t_{n+m-2} = \sqrt{\frac{nm(n+m-2)}{n+m}} \frac{\bar{X} - \bar{Y}}{\sqrt{\sum (X_i - \bar{X})^2 + \sum (Y_i - \bar{Y})^2}}$$

Kritikus tartomány: mint az egymintás esetben

Feltételei: ha ismeretlenek, de azonosak a szórások

- a val.változók függetlenek és normális eloszlásúak

17. Feltételes valószínűség

4.1. definíció: Ha A és B egy kísérlettel kapcsolatos két tetszőleges esemény és $P(B) > 0$, akkor az A esemény B -re vonatkozó feltételes valószínűségét a

$$P(A|B) = \frac{P(A \cdot B)}{P(B)}$$

kifejezéssel definiáljuk.

- Az A esemény valószínűségét keressük.
- Tudjuk, hogy B esemény bekövetkezett.
- A relatív gyakoriságokkal: csak azokat a kísérleteket nézzük, amelyekben B bekövetkezett. Ezen részsorozatban az A relatív gyakorisága:

$$r_{A \cap B} / r_B$$

- Megfelelője a valószínűségekre:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

az A esemény B -re vonatkozó feltételes valószínűsége (feltétel: $P(B) > 0$).

18. Várható érték fogalma diszkrét valószínűségi változóban

7.1. definíció: Legyen X diszkrét valószínűségi változó, mely az x_1, x_2, \dots értékeket veheti fel. Legyen továbbá $p_i = P(X = x_i)$. Ekkor X várható értékén az $E(X) = \sum_i x_i \cdot p_i$ összeget értjük, amennyiben a $\sum_i |x_i| \cdot p_i$ összeg véges. Egyéb esetben azt mondjuk, hogy a várható érték nem létezik.

19. Példa az exponenciális, egyenletes és normális eloszlás alkalmazására

10.2. definíció: Az X valószínűségi változó $\lambda > 0$ paraméterű exponenciális eloszlású, ha sűrűségfüggvénye

$$f(x) = \begin{cases} \lambda \cdot e^{-\lambda \cdot x}, & \text{ha } x > 0; \\ 0 & \text{különben.} \end{cases}$$

A sűrűségfüggvény alapján meghatározható az eloszlásfüggvénye:

$$F(x) = \begin{cases} 1 - e^{-\lambda \cdot x}, & \text{ha } x > 0; \\ 0, & \text{ha } x \leq 0. \end{cases}$$

10.2. tétel: Ha X egy λ paraméterű exponenciális eloszlású valószínűségi változó, akkor X várható értéke és szórása is a λ paraméter reciprokával egyezik meg, azaz

$$E(X) = D(X) = \frac{1}{\lambda}.$$

Exponenciális eloszlással modellezhető például a várakozási-, illetve a sorbanállási idő, továbbá bizonyos típusú berendezések, alkatrészek élettartama is.

10.1. definíció: Az X valószínűségi változó egyenletes eloszlású az $(a; b)$ intervallumon, ha sűrűségfüggvénye

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{ha } a < x < b; \\ 0 & \text{különben.} \end{cases}$$

A sűrűségfüggvény alapján meghatározható az eloszlásfüggvénye

$$F(x) = \begin{cases} 0, & \text{ha } x \leq a; \\ \frac{x-a}{b-a}, & \text{ha } a < x \leq b; \\ 1, & \text{ha } x > b. \end{cases}$$

10.1. tétel: Ha X egyenletes eloszlású valószínűségi változó az $(a; b)$ intervallumon, akkor várható értéke és szórása:

$$E(X) = \frac{a+b}{2}, \quad D(X) = \frac{b-a}{\sqrt{12}}.$$

Alkalmazható

10.3. definíció: Az X folytonos eloszlású valószínűségi változót m, σ ($\sigma > 0$) paraméterű normális eloszlásúnak nevezünk, ha a sűrűségfüggvénye

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}.$$

Eloszlásfüggvénye pedig

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t-m)^2}{2\sigma^2}} dt.$$

Várható értéke és szórása:

$$E(X) = m, \quad D(X) = \sigma.$$

Alkalmazható mérési hibákra, méreteingadozásokra és olyan élettartamvizsgálatokra, ahol a készülékek, alkatrészek rendszeres kopással mennek tönkre.

20. bootstrap módszer

Újramintavételezési eljárás, a becsléseink szórásának vizsgálatára, modellilleszkedés ellenőrzésére használatos. Előnye: rugalmas a minta/statisztika eloszlására vonatkozó feltételek változására. Adott X_1, X_2, \dots azonos F eloszlású, független val. változók (F ismeretlen): $X_n := \{X_1, \dots, X_n\}$ minta. Ebből az X_n -ből m elemű mintát veszünk visszatevéssel (általában $m = n$). $X_m^* = \{X_1^*, \dots, X_m^*\}$ Ebből az új mintából becsülhetjük a számunkra érdekes statisztika eloszlását.

21. Leíró statisztika feladata

Nem a véletlen hatását vizsgálja, hanem a konkrét minta 1. megjelenítése, 2. jellemzőinek kiszámítása a feladata. Adatok elrendezhetőek táblázatban (fontos: forrás feltüntetése), illetve ábrázolhatók grafikusán.

22. Egy- és kétmintás u-próba

Az **egymintás u-próba** (más néven egymintás **z-próba**) a statisztikai hipotézisvizsgálatok közül a paraméteres próbák közé tartozik. A próba azt ellenőrzi, hogy egy adott statisztikai ismérv esetén a mintabeli átlag szignifikánsan eltér-e a populációs átlagtól. Más szavakkal, hogy egy valószínűségi változó átlaga szignifikánsan különbözik-e egy adott m értéktől.

a) Az **egymintás u-próba**. Tegyük fel, hogy X egy $N(m; \sigma)$ normális eloszlású valószínűségi változó, ismeretlen m és ismert σ értékkel. Ellenőrizni akarjuk, hogy az X valószínűségi változó várható értéke m egyenlő-e egy adott m_0 számmal. Egy n elemű minta \bar{X} átlaga általában nem lesz pontosan m_0 . Kérdés: a mintaátlag mekkora eltérése esetén feltételezhetjük, hogy a várható érték m_0 ?

Ha a

$$H_0 : M(X) = m_0$$

nullhipotézis teljesül a

$$H : M(X) = m \neq m_0 \quad (*)$$

ellenhipotézissel szemben, akkor az

$$u = \sqrt{n} \frac{\bar{X} - m_0}{\sigma} \quad (1)$$

formulával képzett u valószínűségi változó (próbafüggvény) $N(0;1)$ standard normális eloszlású. Ekkor a II. rész 2. fejezet 2.2. pontjának (1) relációja alapján az u konfidencia-intervalluma $1-p$ valószínűséggel megadható, azaz

$$P\left(-u_p \leq \sqrt{n} \frac{\bar{X} - m_0}{\sigma} \leq u_p\right) = 1 - p = 2\Phi(u_p) - 1$$

és így a $\Phi(u_p) = 1 - \frac{p}{2}$ összefüggésből adott p -hez u_p értéke a 1. sz. táblázatból visszakereshető. A (*) ún. *kétoldali ellenhipotézis*, mely azt fejezi ki, hogy vagy $m < m_0$ vagy $m > m_0$.

Az (1) képlettel **számított** $u_{sz} = u$ **érték** nagy valószínűséggel (pl. $1 - p = 1 - 0,05 = 0,95$) az $[-u_p; u_p]$ elfogadási tartományba esik, és csak kis valószínűséggel (pl. 0,05) esik a kritikus tartományba.

Azt mondjuk, hogy $100(1-p)\%$ biztonsági szinten elfogadjuk a nullhipotézist, ha

$$|u_{sz}| = \left| \sqrt{n} \frac{\bar{X} - m_0}{\sigma} \right| \leq u_p = u_t$$

23. Hogyan adhatjuk meg megszámlálható valószínűségi mezőn a valószínűséget?

eltérés véletlenszerű, statisztikailag nem igazolható, más szóval az **eltérés nem szignifikáns**.

Azt mondjuk, hogy a H_0 hipotézist $100(1-p)\%$ szinten elutasítjuk, vagyis a H ellentett hipotézist fogadjuk el, ha

$$|u_{sz}| > u_t,$$

azaz ha u_{sz} a kritikus tartományba esik. Ez utóbbi esetben statisztikailag igazoltnak fogadjuk el, hogy az alapsokaság várható értéke és a feltételezett m_0 érték között **szignifikáns különbség** van.

Mint az előző pontban említettük, mindkét döntésünk véletlen folytán téves lehet. Elsőfajú hibát követünk el, ha H_0 hipotézis igaz, de elvetjük az $M(X) = m_0$ feltevést, mert pl. az u_{sz} érték a kritikus tartományra esett. Másodfajú hibát követünk el, ha H_0 hipotézis nem igaz, de elfogadjuk az $M(X) = m_0$ feltevést pl. mert az u_{sz} érték az elfogadási tartományra esett.

b) A **kétmintás u-próba**. Legyen X és Y két normális eloszlású valószínűségi változó, melyekhez X_1, X_2, \dots, X_k és Y_1, Y_2, \dots, Y_m független minták tartoznak, valamint szórásuk, σ_x és σ_y , ismert.

Ha

$$H_0 : M(X) = M(Y)$$

nullhipotézis teljesül a

$$H : M(X) \neq M(Y)$$

ellenhipotézissel szemben, akkor az

$$u = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_x^2}{k} + \frac{\sigma_y^2}{m}}} \quad (2)$$

valószínűségi változó (próbat statisztika) $N(0;1)$ eloszlású, ahol \bar{X} , \bar{Y} a két mintából számított mintaközép. Ekkor a kétmintás u -statisztika u konfidencia-intervalluma $1-p$ valószínűséggel megadható, azaz

$$P(-u_p \leq u \leq u_p) = 1 - p = 2\Phi(u_p) - 1.$$

Az u_p értékét adott p -hez az 1. sz. táblázatból $\Phi(u_p) = 1 - \frac{p}{2}$ összefüggés alapján kiszámíthatjuk. Ha a (2) formulával kiszámított u -statisztika nem esik a $[-u_p; u_p]$ intervallumba, akkor $1-p$ szignifikanciaszinten a nullhipotézist elvetjük, mivel ekkor a kiszámított u értéke a $[-u_p; u_p]$ intervallumon kívüli kritikus tartományba esik.

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_n, \dots\}, \mathcal{A} = \mathcal{P}(\Omega).$$

Jelölés: $p_i = P(\omega_i)$, valószínűségeloszlás:

$p_i \geq 0$, az összegük 1.

A σ -additivitás miatt tetszőleges A eseményre megy a véges esetre látott számítás:

$$P(A) = P(\cup_{i: \omega_i \in A} \omega_i) = \sum_{i: \omega_i \in A} p_i$$

A megszámlálható számosságú valószínűségi mezők (azaz az olyan kísérletek, melyeknek megszámlálható sok kimenetele van) teljesen leírhatók az ún. diszkrét valószínűségeloszlások segítségével.

1.6. Definíció. A p_1, p_2, \dots számsorozatot **diszkrét valószínűségeloszlásnak** (röviden **eloszlásnak**) nevezzük, ha

$$p_i \geq 0, \quad i = 1, 2, \dots, \quad \sum_{i=1}^{\infty} p_i = 1.$$

Ha p_1, p_2, \dots egy diszkrét valószínűségeloszlás, akkor legyen $\Omega = \{\omega_1, \omega_2, \dots\}$ egy tetszőleges megszámlálható halmaz, $\mathcal{F} = 2^\Omega$. A

$$P(A) = \sum_{\omega_i \in A} p_i, \quad A \in \mathcal{F}$$

képlet nyilván valószínűséget definiál, melyre $P(\omega_i) = p_i, i = 1, 2, \dots$.

24. Markov-egyenlőtlenség

2.26. Tétel. (Markov-egyenlőtlenség) Legyen η nemnegatív valószínűségi változó, $\delta > 0$ rögzített szám. Ekkor

$$P(\eta \geq \delta) \leq \mathbb{E}\eta / \delta.$$

Bizonyítás. A következő egyenlőtlenségek érvényesek:

$$\begin{aligned} \mathbb{E}\eta &= \sum_i y_i P(\eta = y_i) \geq \sum_{\{i: y_i \geq \delta\}} y_i P(\eta = y_i) \geq \\ &\geq \delta \sum_{\{i: y_i \geq \delta\}} P(\eta = y_i) = \delta P(\eta \geq \delta). \end{aligned}$$


- Legyen $X \geq 0$ valószínűségi változó, $g: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ monoton növvő. Ekkor $P(X \geq \varepsilon) \leq E(g(X))/g(\varepsilon)$.

- Bizonyítás.

$$E(g(X)) \geq g(\varepsilon)P(X \geq \varepsilon)$$

mert $X \geq \varepsilon$ eseményen

$$g(X) \geq g(\varepsilon)$$



25. Visszatevés nélküli mintavétel modellje és a különböző selejtszámok valószínűségei

A **visszatevés nélküli mintavétel** során vagy egyszerre emeljük ki a minta elemeit a sokaságból, vagy egyenként, de ekkor nem tesszük vissza a már kiválasztott elemeket.

Tegyük fel, hogy az N elemű sokaságban s számú elem rendelkezik egy adott T tulajdonsággal. Ezután válasszunk ki véletlenszerűen n darab elemet visszatevés nélkül! ($n \leq s$, és $n \leq N - s$.) Legyen az X valószínűségi változó értéke az n -elemű mintában kiválasztott T tulajdonságú elemek száma. Bizonyítható, hogy ekkor az X valószínűségi változó hipergeometrikus eloszlású.

- N termék, melyből M selejtes
- n elemű minta visszatevés nélkül
- A : pontosan k selejtes van a mintában ($k=0, \dots, n$)

$$P(A) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$$

Mintavétel

26. Sűrűségfüggvény becslésére tanult eljárás

27. F-próba és a legfontosabb alkalmazásai

25.2.1. F-próba

Az X és az Y normális eloszlású, $D(X) = \sigma_1$ és $D(Y) = \sigma_2$ ismeretlen szórású valószínűségi változók szórásainak egyenlőségére vonatkozó

$$H_0: \sigma_1 = \sigma_2$$

hipotézis helyességét akarjuk ellenőrizni.

A próbastatisztika formula:

$$F_p = \frac{s_1^2}{s_2^2}.$$

A próbastatisztika $(n_1 - 1, n_2 - 1)$ szabadsági fokú F -eloszlású, ha H_0 fennáll.

n_1 az X -re vonatkozó, n_2 az Y -ra vonatkozó független minták elemszáma.

Megjegyzés: Az, hogy az $\frac{s_1^2}{s_2^2}$ hányados értéke 1-nél nagyobb vagy kisebb, attól függ, milyen sorrendben dolgozzuk fel a mintákat. Az F -eloszlás táblázatának használatát megkönnyítendő a számlálóba mindig annak a mintának a korrigált tapasztalati szórásnégyzete kerüljön, amelynél ez az érték nagyobb. Ekkor a hányados értéke nem lehet 1-nél kisebb. Technikailag ez azt jelenti, hogy a próbastatisztikát úgy választjuk, hogy értéke legalább 1 legyen:

$$F_p = \max \left(\frac{s_1^2}{s_2^2}, \frac{s_2^2}{s_1^2} \right) \geq 1.$$

Ennek az a következménye, hogy F -próba esetén az elfogadási tartomány mindig az egyoldali próbának megfelelő $(0, F_{kr})$ lesz.

28. Véletlen szám generálása Neumann módszerével

Legyen $f(x)$ tetszőleges sűrűségfüggvény, $g(x)$ pedig olyan sűrűségfüggvény, amelyre $f(x) < M g(x)$, valamely $M > 1$ esetén és $g(x)$ -ből könnyen tudunk mintát venni (tipikus példa az egyenletes eloszlás).

Algoritmus:

1. Vegyünk mintát: $u \Rightarrow U(0,1)$ -ből, $x \Rightarrow g(x)$ -ből
2. Ha $u < f(x)/Mg(x)$, akkor x -et elfogadjuk
3. Különben elutasítjuk, és 1-be lépünk.

29. χ^2 -négyzet próba és legfontosabb alkalmazásai

A leggyakrabban használt nem-paraméteres próba a χ^2 -próba. Fontos megjegyezni, hogy míg a korábban ismerttetett próbák kis és közepes minták esetében is jól használhatóak, a χ^2 -próba csak nagy elemszámú minták esetében ad megbízható eredményt. Tekintsük át a χ^2 -próba három legfontosabb alkalmazási területét!

a) Illeszkedésvizsgálat

Akkor alkalmazzuk, ha azt akarjuk ellenőrizni, hogy a minta adott eloszlású populációból származik-e. A gyakorlatban ez azt jelenti, hogy azt vizsgáljuk, hogy a mintából származó gyakoriságok mennyire illeszkednek az eloszlásból származó becsült gyakoriságokra. Adott egy n elemű minta, a mintaelemeket osszuk r (párként diszjunkt) csoportba, azaz tekintsük az A_1, A_2, \dots, A_r teljes eseményrendszert. Az A_i esemény valószínűségét p_i , gyakoriságát (hány mintaelem esik az i -edik csoportba) pedig μ_i jelölje ($i = 1, 2, \dots, r$ esetén).

Az eloszlásra vonatkozó $H_0 : P(A_i) = p_i$ ($i = 1, 2, \dots, r$) nullhipotézist akarjuk ellenőrizni, azaz azt, hogy a megfigyelt valószínűségi változó adott eloszlású.

A próbat statisztika:

$$\chi_p^2 = \sum_{i=1}^r \frac{(\mu_i - n \cdot p_i)^2}{n \cdot p_i}$$

Eloszlása: $r - 1$ szabadsági fokú χ^2 -eloszlás, ha H_0 fennáll.

(Pontosabban $n \rightarrow \infty$ esetén $r - 1$ szabadsági fokú χ^2 -eloszlással közelíthető. A gyakorlatban azonban a fenti próbat statisztikát $r - 1$ szabadsági fokú χ^2 -eloszlásúnak tekintjük.)

A próba mindig egyoldali, jobb oldali kritikus tartománnyal. (Vegyük észre, ha a feltételezett eloszlás különbözik

b) Homogenitásvizsgálat

Akkor alkalmazzuk, ha azt akarjuk eldönteni, hogy két független minta azonos eloszlásból származik-e. (Anélkül, hogy a konkrét eloszlást meghatároznánk.)

Jelölje X és Y a megfigyelt valószínűségi változókat. Az X -re vonatkozó minta elemszáma legyen m , az Y -ra vonatkozó minta elemszáma n . Soroljuk valamilyen szempont szerint r csoportba a mintaelemeket. Jelölje μ_i az X , ν_i az Y megfigyeléséből származó minta i -edik csoportba eső mintaelemeinek számát (azaz az A_i , illetve

B_i események gyakoriságát). $\left(\sum_{i=1}^r \mu_i = m, \sum_{i=1}^r \nu_i = n \right)$.

A nullhipotézisünk az, hogy a két minta azonos eloszlásból származik.

A próbat statisztika:

$$\chi_p^2 = \frac{1}{m \cdot n} \sum_{i=1}^r \frac{(n \cdot \mu_i - m \cdot \nu_i)^2}{\mu_i + \nu_i}$$

Eloszlása: H_0 fennállása esetén $r - 1$ szabadsági fokú χ^2 -eloszlás.

A próba most is egyoldali, jobb oldali kritikus tartománnyal. (Vegyük észre, ha a két minta eloszlása különböző, akkor a próbat statisztika értéke a formulából adódóan nagy. Minél nagyobb ez a számított érték, annál nagyobb ez az eltérés.)

c) Függetlenségvizsgálat

Azt akarjuk eldönteni, hogy két valószínűségi változó, X és Y függetlenek-e. Az (X, Y) valószínűségi változó megfigyelésére n elemű mintát veszünk. Az X valószínűségi változó értékeit r , Y értékeit s csoportba soroljuk, azaz létrehozuk X -re vonatkozóan az A_1, A_2, \dots, A_r , Y -ra vonatkozóan a B_1, B_2, \dots, B_s teljes eseményrendszereket. Jelölje μ_{i*} az A_i ($i = 1, 2, \dots, r$), ν_{*j} a B_j ($j = 1, 2, \dots, s$) bekövetkezésének gyakoriságát,

μ_{ij} pedig az (A_i, B_j) együttes bekövetkezésének gyakoriságát. Természetesen ekkor teljesül, $\sum_{i=1}^r \sum_{j=1}^s \mu_{ij} = 1$,

valamint, hogy $\sum_{i=1}^r \mu_{ij} = \nu_{*j}$, és $\sum_{j=1}^s \mu_{ij} = \mu_{i*}$. (Ez utóbbiakhoz idézzük fel a valószínűségi vektorváltozók peremeloszlásait diszkrét esetben!)

A feltevésünk, hogy a két valószínűségi változó független, vagyis (A_1, A_2, \dots, A_r) és (B_1, B_2, \dots, B_s) teljes eseményrendszerek függetlenek. A nullhipotézis formálisan az, hogy $P(A_i \cdot B_j) = P(A_i) \cdot P(B_j)$ ($i = 1, 2, \dots, r$, $j = 1, 2, \dots, s$ esetén).

A próbat statisztika:

$$\chi_p^2 = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^s \frac{(n \cdot \mu_{ij} - \mu_{i*} \cdot \nu_{*j})^2}{\mu_{i*} \cdot \nu_{*j}}$$

Eloszlása: $(r - 1) \cdot (s - 1)$ szabadsági fokú χ^2 -eloszlás, amennyiben H_0 fennáll.

A próba egyoldali, jobb oldali kritikus tartománnyal, hasonlóan az illeszkedés-, illetve a homogenitásvizsgálathoz.

30. Becsléses illeszkedés vizsgálat és hogyan alkalmazzuk rá a χ^2 -négyzet próbát

31. Szekvenciális próba (egyszerű hipotézisek esetére)

A valószínűséghányados
n elemű mintából

$$V_n = \frac{\prod_{i=1}^n f_1(X_i)}{\prod_{i=1}^n f_0(X_i)}$$

Addig veszünk mintaelemeket,
amíg $V_n \geq B$ vagy $V_n \leq A$ nem teljesül

Tehát az algoritmus:

- $V_n \geq B$: elutasítjuk H_0 -t.
 - $V_n \leq A$: elfogadjuk H_0 -t.
 - $B > V_n > A$: új mintaelemet veszünk.
- 1 valószínűséggel véges az N , ahol

$$N = \min \{n : V_n \leq A \text{ vagy } V_n \geq B\}$$

32. Korrelációs együttható és legfontosabb tulajdonságai

- A kovariancia skálafüggő: $\text{cov}(aX, bY) = ab \cdot \text{cov}(X, Y)$
- A változók közötti lineáris kapcsolat erősségét mérő mennyiség a *korrelációs együttható*:

$$R(X, Y) = \frac{\text{cov}(X, Y)}{D(X)D(Y)}$$

- Tulajdonságai:
 - $R(X, Y) = 0$, ha X és Y függetlenek (ez sem fordítható meg)
 - Ez alapján definíció szerint legyen $R(X, Y) = 0$, ha X vagy Y elfajult eloszlású.
 - $R(X, aX + b) = 1$, ha $a > 0$, mert $\text{cov}(X, aX + b) = aD^2(X)$.

Két valószínűségi változó közötti kapcsolat szorosságát kifejezhetjük a korrelációs együtthatóval. A korrelációs együttható lényegében két vektor által bezárt szög koszinuszát jelenti.

2.31. Definíció. Legyen $0 < D^2\xi, D^2\eta < \infty$. A ξ és η korrelációs együtthatóján a

$$\text{corr}(\xi, \eta) = \frac{\text{cov}(\xi, \eta)}{D\xi D\eta}$$

mennyiséget értjük. Ha $\text{corr}(\xi, \eta) = 0$, akkor ξ -t és η -t **korrelálatlanoknak** nevezzük. Ha ξ és η függetlenek, akkor korrelálatlanok, de ez fordítva nem igaz.

33. Mikor nevezünk egy torzítatlan becslést hatásosabbnak egy másiknál?

A becslés hatásfoka Bárki megkérdezheti tehát, hogy két torzítatlan becslés közül melyik a jobb becslés. A válasz elég nyilvánvaló, ha egy kételemű minta alapján kell a ξ valószínűségi változó $E(\xi)$ várható értékének az alábbi két torzítatlan becslése közül választanunk:

$$1) \tilde{\vartheta} = \frac{\xi_1 + \xi_2}{2},$$

$$2) \hat{\vartheta} = -7\xi_1 + 8\xi_2.$$

A $\hat{\vartheta}$ szórása sokkal nagyobb a $\tilde{\vartheta}$ szórásánál, így feltehetően mindenki az 1) számú becslést választaná.

Definíció: Legyen adott a ϑ paraméter két $\hat{\vartheta} = \hat{\vartheta}(\xi_1, \xi_2, \dots, \xi_n)$ és $\tilde{\vartheta} = \tilde{\vartheta}(\xi_1, \xi_2, \dots, \xi_n)$ torzítatlan becslése. A $\tilde{\vartheta}$ becslést **hatásosabbnak** nevezzük a $\hat{\vartheta}$ becslésnél, ha

$$D^2(\tilde{\vartheta}) \leq D^2(\hat{\vartheta})$$

a ϑ paraméter minden lehetséges értékére.

34. Trend és a periódus fogalma idősorokra

a)Trend

Az idősorban hosszabb időszakon át tartósan érvényesülő tendencia

b) Periódus

Az i állapot periódusa d_i ha $d_i = \text{lcm}\{k: p_i^{(k)} > 0\}$.

35. Nagy számok gyenge törvénye

36. Szita (Poincaré) formula

Képlet az általános esetre:

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = \sum_{i=1}^n (-1)^{i+1} S_i^{(n)}$$

ahol

$$S_i^{(n)} = \sum_{1 \leq j_1 < j_2 < \dots < j_i \leq n} P(A_{j_1} \cap A_{j_2} \cap \dots \cap A_{j_i})$$

az i tényezős metszetek
valószínűségeinek összege.

A valószínűségszámításban Poincaré formula néven is ismert állítás a következő:

3. Tétel. (Nagy számok gyenge törvénye):

Legyenek az $X_1, X_2, \dots, X_n, \dots$ valószínűségi változók függetlenek; eloszlásuk m -mel jelölt várható értékük, s^2 -tel jelölt szórásnégyzetük azonos, akkor az

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

számtani közép sztochasztikusan konvergál az m várható értékhez, ha n minden határon túl nő, azaz

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - m| \geq \varepsilon) = 0 \quad \text{vagy} \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - m| < \varepsilon) = 1. \quad (1)$$

$$\text{U.i. } M(\bar{X}_n) = \frac{M(X_1) + M(X_2) + \dots + M(X_n)}{n} = \frac{n \cdot m}{n} = m,$$

s mivel X_1, X_2, \dots, X_n független valószínűségi változók, ezért

$$P(A_1 \cup \dots \cup A_n)$$

ahol $S_i^{(n)}$ az összes i -tényezős metszet való

$$S_i^{(n)} = \sum_{1 \leq k_1 < k_2 < \dots < k_i \leq n} 1$$

Sok esetben pedig az az egyszerű átfogalmazás még praktikusabb, ahol unió helyett metszet szerepel:

ahol legyen $S_0^{(n)} := 1$. A két állítás ekvivalenciája abból adódik, hogy a komplementerek metszete éppen azt jelenti, hogy egyik esemény sem következik be – ez pedig éppen az unió komplementere. A jobb oldal pedig éppen 1- a komplementer esemény valószínűsége.

37. Kovariancia és tulajdonságai

$$D^2(X_1 + X_2 + \dots + X_n) =$$

$$= D^2(X_1) + D^2(X_2) + \dots + D^2(X_n) = n \cdot s^2.$$

Tekintettel arra, hogy

$$D^2(\bar{X}_n) = D^2\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) =$$

$$= \frac{1}{n^2} D^2(X_1 + X_2 + \dots + X_n) =$$

$$= \frac{1}{n^2} (n \cdot s^2) = \frac{s^2}{n}$$

így a Csebisev-egyenlőtlenség (5) alakját használva:

$$P(|\bar{X}_n - m| \geq \varepsilon) \leq \frac{s^2}{n\varepsilon^2},$$

- Definíció. Az X és Y kovarianciája:
 $\text{cov}(X,Y) := E[(X-E(X))(Y-E(Y))]$
- Kiszámítása: $\text{cov}(X,Y) = E[XY - XE(Y) - YE(X) + E(X)E(Y)] = E(XY) - E(X)E(Y)$
- A korábban látott, független val.változókra vonatkozó $E(XY) = E(X)E(Y)$ egyenlőség értelmében $\text{cov}(X,Y) = 0$, ha X és Y függetlenek.
- Megj.: Abból, hogy $\text{cov}(X,Y) = 0$ nem következik, hogy függetlenek: legyen X szimmetrikus a 0-ra (pl. $P(X=1) = P(X=-1) = P(X=0) = 1/3$) és $Y = X^2$. Ekkor $\text{cov}(X,Y) = E(X^3) - E(X)E(X^2) = 0 - 0$, hiszen $E(X^3) = E(X) = 0$.
- A kovariancia szimmetrikus: $\text{cov}(X,Y) = \text{cov}(Y,X)$
- $\text{cov}(X,X) = D^2(X)$

Definíció. Legyen X és Y diszkrét, véges valószínűségi változók együttes eloszlása w , a várható értékeket jelölje m_x és m_y , akkor az X és Y változók $\text{Cov}(X,Y)$ -nal jelölt **kovarianciáján** a

$$\text{Cov}(X,Y) = \sum_{i,j} (x_i - m_x)(y_j - m_y)w(x_i, y_j) = M((X - m_x)(Y - m_y)) \quad (4)$$

számot értjük.

Míthogy az X és Y diszkrét, véges valószínűségi változók, ezért a

$$\sum_{i,j} y_j w(x_i, y_j) = \sum_j y_j u(y_j) = m_y;$$

$$\sum_{i,j} x_i w(x_i, y_j) = \sum_i x_i v(x_i) = m_x$$

és a

$$\sum_{i,j} w(x_i, y_j) = 1$$

összefüggések felhasználásával a (4) képletet számításra alkalmasabb alakra hozhatjuk:

$$\begin{aligned} \text{Cov}(X, Y) &= \sum_{i,j} (x_i - m_x)(y_j - m_y)w(x_i, y_j) = \\ &= \sum_{i,j} x_i y_j w(x_i, y_j) - m_x m_y = M(XY) - m_x m_y. \end{aligned} \quad (5)$$

Ha X és Y független valószínűségi változók, akkor

$$w(x_i, y_j) = v(x_i) \cdot u(y_j),$$

és így

$$\begin{aligned} M(XY) &= \sum_{i,j} x_i y_j w(x_i, y_j) = \sum_{i,j} x_i y_j v(x_i) \cdot u(y_j) = \\ &= \sum_i x_i v(x_i) \cdot \sum_j y_j u(y_j) = M(X)M(Y). \end{aligned}$$

Az $M(XY) = M(X)M(Y)$ -ből (5)-re tekintettel következik, hogy $\text{Cov}(X, Y) = 0$, de ez fordítva nem áll fenn, azaz $\text{Cov}(X, Y) = 0$ -ból nem következik X és Y változók függetlensége. Mivel a kovariancia nagyságát jelentősen befolyásolja a vizsgálatba bevont (x_i, y_j) adatpárok mértékegysége, ezért ennek kiküszöbölésére az

$$\frac{X - m_x}{D(X)} \quad \text{és az} \quad \frac{Y - m_y}{D(Y)}$$

standardizált változók kovarianciáját képezzük, mely már dimenziómentes:

$$\text{Cov}\left(\frac{X - m_x}{D(X)}, \frac{Y - m_y}{D(Y)}\right) = \frac{\text{Cov}(X, Y)}{D(X)D(Y)}.$$

Az összefüggés szorossága így függetleníthető az (x_i, y_j) adatpárok, a változók mértékegységétől. Ezek figyelembevételével kimondható a következő

38. Abszolút folytonos valószínűségi változók függetlenségének ekvivalens jellemzői

1.32. Tétel. Legyen (ξ_1, \dots, ξ_n) abszolút folytonos valószínűségi vektorváltozó. A ξ_1, \dots, ξ_n valószínűségi változók pontosan akkor függetlenek, ha

$$f(x_1, \dots, x_n) = \prod_{k=1}^n f_k(x_k)$$

teljesül minden $x_1, \dots, x_n \in \mathbb{R}$ esetén, ahol f_k a ξ_k sűrűségfüggvénye, továbbá f a (ξ_1, \dots, ξ_n) sűrűségfüggvénye.

39. Szórásnégyzet és legfontosabb tulajdonságai

Nem mindegy, hogy mekkora a vizsgált véletlen mennyiség ingadozása.

Jobb, ha a buszok pontosan 10 percenként jönnek, mintha időnként 3 jön egymás után, és aztán 30 percet kell várni.

Az ingadozás számszerűsítése: a várható értéktől vett átlagos négyzetes eltérés, elnevezése: szórásnégyzet. Formálisan:

$$D^2(X) = E[(X - E(X))^2].$$

$$\text{Kiszámítása: } D^2(X) = E[X^2 - 2XE(X) + E^2(X)] = E(X^2) - 2E(X)E(X) + E^2(X)$$

a várható érték linearitása miatt. Azaz

$$D^2(X) = E(X^2) - E^2(X).$$

- $D^2(X) \geq 0$, mert nemnegatív valószínűségi változó várható értéke.
- $D^2(aX+b) = a^2 D^2(X)$, mert $D^2(aX+b) = E[(aX+b-E(aX+b))^2] = E[(aX+b-aE(X)-b)^2] = E[(aX-aE(X))^2] = a^2 E[(X-E(X))^2]$.
- Abból, hogy $E(X)$ véges, még nem következik $D^2(X)$ végeessége, hiszen ha $P(X=k) = c/k^3$ (egyértelműen megadható olyan c , amire ez eloszlás lesz) akkor $E(X)$ véges, de $E(X^2) = c(1+1/2+\dots+1/k+\dots)$, ami végtelen.

Definíció. Az X valószínűségi változó **szórásnégyzetének (varianciájának)** az $(X - m)^2$ valószínűségi változó várható értékét nevezzük, azaz a

$$D^2(X) = \sum_{i=1}^n (x_i - m)^2 v(x_i) = M((X - m)^2) \quad (1)$$

formulával adott számot, ahol m az X várható értéke ($m = M(X)$).

A szórásnégyzet szokásos jelölése még s^2 , σ^2 és $\text{Var}(X)$.

A szórásnégyzet jellemzi tehát az X -re vonatkozó egyes mérési adatok eltérését átlaguktól. Más szóval az adatok négyzetes közép-hibája $D^2(X)$ körül ingadozik.

Definíció. Ha az X folytonos eloszlású valószínűségi változónak $f(x)$ a sűrűségfüggvénye, akkor **szórásnégyzetét és szórását** a

$$D^2(X) = M((X - m)^2) = \int_{-\infty}^{\infty} (x - m)^2 f(x) dx \quad (2)$$

$$D(X) = \sqrt{\int_{-\infty}^{\infty} (x - m)^2 f(x) dx} \quad (3)$$

képletekkel definiáljuk, ahol $m = M(X)$, feltéve hogy a jobb oldali integrál létezik.

A (2) formula alapján azt is mondhatjuk, hogy a szórásnégyzet az $(X - M(X))^2$ valószínűségi változó várható értéke, ha létezik.

A diszkrét esethez hasonlóan az $m = M(X)$ és $M(X^2)$ létezése szükséges és elegendő feltétel a $D^2(X)$ létezéséhez, és így a szórásnégyzetet és a szórását a következő képletekkel is számíthatjuk:

$$D^2(X) = M(X^2) - m^2 = \int_R x^2 f(x) dx - m^2 \quad (4)$$

$$D(X) = \sqrt{M(X^2) - m^2} = \sqrt{\int_R x^2 f(x) dx - m^2}. \quad (5)$$

40. Lineáris regresszió feladata és megoldása

A túlhatározott egyenletrendszerek egy speciális esetének tekinthető a lineáris regresszió. Adott n darab pont, koordinátáik: $P_i = (x_i; y_i)$ ($i = 1, \dots, n$). Ezek a pontok nem illeszkednek ez egyenesre. Az a feladat, hogyan határozzuk meg a legkisebb négyzetek módszerének a felhasználásával a pontokat legjobban megközelítő egyenes, az ún. regressziós egyenes egyenletét. Az egyenes egyenlete $y = \alpha x + \beta$, ahol az α, β valós paraméterek.

41. Adjon módszert idősorok simítására

Nem stacionárius idősor esetén a megfigyelhető trendet leválasztjuk, majd az egyes periódusokra kiszámoljuk a reziduálisok átlagát. Ezt kivonva az eredeti idősorból, periódusmentes adatokat kapunk.

42. Centrális határeloszlás tétele

7.4 Tétel (Centrális határeloszlástétel független, azonos eloszlású változókra)

Legyenek

ξ_1, ξ_2, \dots független, azonos eloszlásúak, $m := E\xi_1$ és $0 < \sigma^2 = D^2\xi_1 < \infty$. Ekkor minden $x \in \mathbb{R}$ -re

$$P\left(\frac{\sum_{i=1}^n \xi_i - n \cdot m}{\sigma \cdot \sqrt{n}} < x\right) \rightarrow \Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{t^2}{2}} dt$$

Legyenek $X_1, X_2, \dots, X_n, \dots$ független, azonos eloszlású valószínűségi változók. Tegyük fel, hogy $\sigma^2 = D^2(X)$ véges ($m := E(X)$). Tekintsük a standardizált összegüket:

$$Z_n := \frac{X_1 + \dots + X_n - nm}{\sqrt{n}\sigma}$$

Ekkor Z_n gyengén konvergál a standard normális eloszláshoz, azaz

$$P\left(\frac{X_1 + \dots + X_n - nm}{\sqrt{n}\sigma} < z\right) \rightarrow \Phi(z)$$

ahol Φ a standard normális eloszlás eloszlásfüggvénye.

43. Lokális centrális határeloszlás tétele

Legyenek $X_1, X_2, \dots, X_n, \dots$ független, azonos eloszlású valószínűségi változók. Tegyük fel, hogy $\sigma^2 = D^2(X)$ véges ($m := E(X)$) valamint, hogy abszolút folytonosak, szakaszonként folytonos sűrűségfüggvénnyel. Tekintsük a standardizált összegüket (Z_n) és tegyük fel, hogy legalább egy n -re Z_n sűrűségfüggvénye korlátos. Ekkor a Z_n változó f_n sűrűségfüggvénye (mely a tagok abszolút folytonossága miatt létezik) konvergál a standard normális eloszlás sűrűségfüggvényéhez, azaz

$$f_n(t) \rightarrow \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$$

44. Teljes eseményrendszer fogalma

Definíció. Legyen A_1, A_2, \dots, A_n , $A_k \neq \emptyset$ ($k = 1, 2, \dots, n$) az események olyan halmaza, amelyre $A_i \cdot A_j = \emptyset$ ($i, j = 1, 2, \dots, n$; $i \neq j$) és $A_1 + A_2 + \dots + A_n = I$ teljesül, azaz összegük (uniójuk) a biztos esemény és páronkénti szorzatuk (metszetük) a lehetetlen esemény. Ekkor a

$$Q = \{A_1, A_2, \dots, A_n\}$$

eseményhalmazt **teljes eseményrendszernek** nevezzük.

A teljes eseményrendszer eseményei közül – a definíció értelmében, az eseményekre vonatkozó kísérlet során – mindig egy esemény következik be, és nem több.

Definíció. Események A_1, A_2, \dots , sorozata *teljes eseményrendszer*, ha egymást páronként kizárják és egyesítésük Ω .

Tulajdonság: $P(A_1) + P(A_2) + \dots = 1$

Legtöbbször véges sok elemből álló teljes eseményrendszereket vizsgálunk.

45. Definíálja folytonos eloszlásra a várható érték fogalmát!

Definíció. Ha az X folytonos eloszlású valószínűségi változónak $f(x)$ a sűrűségfüggvénye, akkor **várható értéke**:

$$M(X) = \int_{-\infty}^{\infty} xf(x)dx \quad (1)$$

feltéve, hogy az improprius integrál abszolút konvergens, azaz

$$\int_{-\infty}^{\infty} |x|f(x)dx < +\infty.$$

Tehát az (1) formula csak akkor áll fenn, ha a jobb oldali integrál létezik és véges.

46. Bernstein tétele

Tétel (Bernstein). Legyen (X_1, X_2, \dots, X_n) olyan, hogy $D^2(X_1) + D^2(X_2) + \dots + D^2(X_n) < kn$, valamint tegyük fel, hogy van olyan $h: \mathbf{N} \rightarrow \mathbf{R}_+$ függvény, melyre $|R(X_i, X_j)| \leq h(|i-j|)$ és $\frac{1}{n} \sum_{i=1}^n h(i) \rightarrow 0$ ekkor $(X_1 + X_2 + \dots + X_n)/n - (m_1 + m_2 + \dots + m_n)/n \rightarrow 0$ sztochasztikusan.

Cantor –Schröder-Bernstein-tétel: Tetszőleges A és B halmazok esetén, ha létezik $\varphi: A \rightarrow B$ bijektív leképezés is, tehát az A és a B halmaz ekvivalens egymással. Egy halmazon értelmezett összes karakterisztikus függvény halmazának vonatkozó állítás: $BA = \{\varphi: A \rightarrow B\}$ az összes $A \rightarrow B$ leképezés. Ha $A = \{a_1, \dots, a_n\}$ és $B = \{b_1, \dots, b_m\}$, akkor az összes $A \rightarrow B$ leképezés: m^n db. $\{0,1\}^A = \{\varphi: A \rightarrow \{0,1\}\}$ az összes $A \rightarrow \{0,1\}$ leképezés.

47. Maximum-likelihood módszer

$$L(\theta; \underline{x}) = f_{\theta}(\underline{x}) = \prod_{i=1}^n f_{\theta}(x_i)$$

(a likelihood függvény) maximumhelye lesz a θ paraméter maximum likelihood becslése.

Ha a függvény deriválható, a loglikelihood függvény

$$l(\theta; \underline{x}) = \ln f_{\theta}(\underline{x}) = \sum_{i=1}^n \ln f_{\theta}(x_i)$$

maximumhelye deriválással

$$\frac{\partial}{\partial \theta} l(\theta; \underline{x}) = \frac{\partial}{\partial \theta} \ln f_{\theta}(\underline{x}) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln f_{\theta}(x_i) = 0$$

megoldásaként megtalálható

48. Abszolút folytonos valószínűségi vektorváltozó fogalma

5.10 Definíció A ξ valószínűségi változó abszolút folytonos eloszlású, ha létezik olyan nemnegatív f függvény, hogy $F_{\xi}(x) = P(\xi < x) = \int_{-\infty}^x f(s) ds$. Az f függvényt a valószínűségi változó sűrűségfüggvényének nevezzük.

X valószínűségi vektorváltozó abszolút folytonos, ha létezik olyan $f_X(x_1, x_2, \dots, x_n)$ függvény, amelyre $F_X(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_X(t_1, \dots, t_n) dt_1, \dots, dt_n$. Ilyenkor $f_X(x)$ -et sűrűségfüggvénynek nevezzük.

49. (n, p) paraméterű binomiális eloszlás várható értékének levezetése

Az (n, p) paraméterű binomiális eloszlás várható értéke:

$$E(X) = \sum_{k=1}^n k \binom{n}{k} p^k (1-p)^{n-k} = \sum_{k=1}^n np \binom{n-1}{k-1} p^{k-1} (1-p)^{n-k} = np$$

50. Hipergeometriai eloszlás várható értékének levezetése

Visszatevés nélküli mintavételnél adott típusú mintaelemek száma.

$$E(X) = \sum_{k=1}^n k \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}} = \sum_{k=1}^n n \frac{M}{N} \frac{\binom{M-1}{k-1} \binom{N-1-(M-1)}{n-1-(k-1)}}{\binom{N-1}{n-1}} = n \frac{M}{N}$$

51. Poisson eloszlás várható érték levezetése

$$E(X) = \sum_{k=1}^{\infty} k \lambda^k \frac{e^{-\lambda}}{k!} = \sum_{k=1}^{\infty} \lambda^k \frac{e^{-\lambda}}{(k-1)!} = \lambda \sum_{k=1}^{\infty} \lambda^{k-1} \frac{e^{-\lambda}}{(k-1)!} = \lambda$$

52. Egyenletes eloszlás várható értékének levezetése

Az x_1, x_2, \dots, x_n számokon egyenletes eloszlás (mindegyik valószínűsége $1/n$) várható értéke a számok számtani közepe.

Ha X egyenletes eloszlású az $[a, b]$ -ben, akkor

$$E(X) = \int_a^b \frac{y}{b-a} dy = \left[\frac{y^2}{2(b-a)} \right]_a^b = \frac{a+b}{2}$$

53. Exponenciális eloszlás várható értékének levezetése

Ha X exponenciális eloszlású λ paraméterrel, akkor

$$E(X) = \int_0^{\infty} \lambda y e^{-\lambda y} dy = \left[-y e^{-\lambda y} \right]_0^{\infty} + \int_0^{\infty} e^{-\lambda y} dy = \frac{1}{\lambda}$$

54. Standard normális eloszlás várható értékének levezetése

Ha X standard normális eloszlású, akkor

$$E(X) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \left[-\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \right]_{-\infty}^{\infty} = 0$$

55. Hogyan generálna normális eloszlású véletlen számot?

Box-Müller módszer

- Legyen U, V független, $E[0;1]$ eloszlású. Ekkor

$$\sqrt{-2 \ln U} \sin(2\pi V), \sqrt{-2 \ln U} \cos(2\pi V)$$

két független standard normális eloszlású változó lesz.

56. Véletlen szám generálás inverz módszerrel

Az Y_t diszkrét paraméterű sztochasztikus folyamatok k -ad rendű autoregresszív folyamatnak nevezzük, ha

$$Y_t = \alpha_1 * Y_{t-1} + \dots + \alpha_k * Y_{t-k} + \varepsilon_t$$

Tétel: Legyen X val. vált., F eloszlásfüggvénnyel, amely monoton növekedő és folytonos. Ekkor

- $F(X)$ egyenletes eloszlású $[0,1]$ -en
- Ha $U \sim U(0,1)$ akkor $F^{-1}(U)$ eloszlásfüggvénye F .

Pl.: Ha $X \sim \exp(\lambda) \rightarrow F(x)=1-\exp(-\lambda x)$

$$\rightarrow F^{-1}(x) = -\ln(1-x)/\lambda$$

$$\rightarrow -\ln(1-U)/\lambda \sim \exp(\lambda)$$

Ahol:

► α_i konstansok

► Y_t fehér zaj (várható értéke 0, szórása σ_y)

Kiterjesztése: általánosított inverz: $F^{-1}(x) = \inf\{x \mid F(x) \geq x\}$

57. Wilcoxon-próba

A Wilcoxon-féle előjeles rangpróba nem csak az előjeleket, hanem a különbségek közötti nagyságrendeket is figyelembe veszi, így nagyobb erejű, mint az előjelpróba. Az előjelpróbával szemben ennél a próbánál feltétel, hogy a különbség-eloszlás szimmetrikus legyen. Végrehajtása a következő: a mintaelemek közötti különbségeket rangsoroljuk az előjelektől függetlenül, az esetleges nullákat kihagyjuk.

A rangsorolást a következőképpen végezzük: az adatsort nagyság szerint sorba rendezzük, és a legkisebbnek adjuk az 1-es rangszámot, a következőnek a 2-est, stb. Összesen n rangszámot osztunk ki. Egyenlő adatok esetén is egyre növekvő rangszámot adunk, majd az egyenlő adatokhoz tartozó rangszámokat utólag korrigáljuk a megfelelő rangszámok átlagával (a korrigált rangszámokat kapcsolt rangszámoknak nevezzük). A rangsorolás helyességét úgy ellenőrizhetjük, hogy összeadjuk a kapott rangszámokat, ennek az összegnek meg kell egyeznie $n(n+1)/2$ -vel (az első „ n ” egész szám összegével).

A próba során ezután külön összeadjuk a pozitív vagy a negatív különbségekhez tartozó rangszámokat (sőt, elég csak az egyiket). Ha igaz a nullhipotézis és a két sokaság azonos eloszlású, akkor a pozitív és a negatív különbségekhez tartozó rangszámösszegek körülbelül egyformák lesznek. Minél nagyobb az eltérés valamelyik a két sokaság között, annál nagyobb lesz az eltérés a két rangszámösszeg között is. Mekkora eltérést tekinthetünk még véletlenszerűnek? Kis mintaelemszám esetén ($n \leq 30$ vagy $n \leq 50$) táblázatok állnak rendelkezésre, amelyek adott -hoz megadják azt az intervallumot, amekkora rangszámösszeg még véletlen eltérésnek tekinthető. Nagy mintaelemszám esetére, vagy ha nagyon sok a kapcsolt rang, egy közelítően normális eloszlású statisztika segítségével a normális eloszlás alapján vizsgálható a szignifikancia:

$$Z = \frac{\sum_{i=1}^n R_i}{\sqrt{\sum_{i=1}^n R_i^2}}$$

Itt a számlálóban az összes előjeles rangszám összege szerepel, a nevezőben pedig ezek négyzetösszegéből vont négyzetgyök. A számítógépes programrendszerek általában csak ezt a normális közelítésből származó p -értéket számítják ki még kis mintaelemszám esetén is, amikor pedig a közelítés nem túl jó.

58. Autoregressziós –és mozgóátlag folyamatok

■ Autoregressziós folyamatok (AR)

$$X_t = a_1 X_{t-1} + a_2 X_{t-2} + a_3 X_{t-3} + \dots + a_p X_{t-p} + \varepsilon_t$$

- Stacionárius, ha az $1 - (a_1 s + a_2 s^2 + \dots + a_p s^p) = 0$ egyenlet gyökei az egységkörön kívül helyezkednek el

■ Mozgóátlag folyamatok (MA)

$$X_t = b_1 \varepsilon_{t-1} + b_2 \varepsilon_{t-2} + b_3 \varepsilon_{t-3} + \dots + b_q \varepsilon_{t-q} + \varepsilon_t$$

- Mindig stacionárius
- Kombináció: ARMA folyamatok

Az Y_t diszkrét paraméterű sztochasztikus folyamatot k -ad rendű mozgóátlag folyamatnak nevezzük, ha

$$Y_t = \beta_0 * U_t + \beta_1 * U_{t-1} + \dots + \beta_k * U_{t-k}$$

Ahol

- ▶ β_k konstansok
- ▶ U_t diszkrét fehér zaj (várható érték 0, szórás σ_u)

ARMA(p,q)

$$Y_t = \alpha_1 Y_{t-1} + \alpha_2 Y_{t-2} + \dots + \alpha_p Y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \dots + \beta_q \varepsilon_{t-q},$$

Autoregresszív és Mozgóátlag modellek (autoregressive and moving-average)

Sztochasztikus idősoranalízis legegyszerűbb és leginkább elterjedt módszere

Ahol

- ▶ ε_t fehér zaj
- ▶ p és q az autoregresszív és mozgóátlag folyamat rendje

AR és MA folyamatokat egyesít

Paraméterek megállapítása általában empirikus idősor alapján

59. Mit jelent a becslési illeszkedésvizsgálat és hogyan alkalmazzuk rá a χ^2 -négyzet próbát?

Ha a vizsgálat csak arra vonatkozik, hogy valamilyen típusú eloszlás feltételezhető-e, az eloszlás paramétereit a mintából becsülve, akkor becslési illeszkedésvizsgálatokat alkalmazunk.

A gyakorlatban az eloszlásfüggvény alakjára van feltételezésünk, azonban az eloszlásfüggvény bizonyos paraméterei nem ismertek. Legyen

$$H_0 : P(X < t) = F(t; \vartheta_1, \dots, \vartheta_s),$$

ahol az $F(t; \vartheta_1, \dots, \vartheta_s)$ eloszlásfüggvényében a $(\vartheta_1, \dots, \vartheta_s)$ (egydimenziós) paraméterek ismeretlenek. A minta alapján becsüljük meg az ismeretlen paramétereket maximum-likelihood módszerrel. Jelölje $\hat{\vartheta}_i$ a ϑ_i maximum-likelihood becslését. Vizsgáljuk a

$$H'_0 : P(X < t) = F(t; \hat{\vartheta}_1, \dots, \hat{\vartheta}_s)$$

hipotézist a korábban ismertetett eljárással. A módszerben a változás csupán annyi, hogy a χ^2 -eloszlás szabadsági fokát a becsült paraméterek számával kell csökkenteni, azaz a kritikus értéket χ^2_{r-1-s} táblázatából kell kikeresni.

H_0 hipotézis: az A_1, A_2, \dots, A_r teljes eseményrendszerre teljesül $P(A_1)=p_1, P(A_2)=p_2, \dots, P(A_r)=p_r$

A tesztstatisztika:
$$\sum_{i=1}^r \frac{(v_i - np_i)^2}{np_i}$$

ami aszimptotikusan $r-1$ szabadságfokú χ^2 -négyzet eloszlású, ha igaz a nullhipotézis.

Kritikus tartomány: ha a statisztika értéke nagyobb, mint az $r-1$ szabadságfokú χ^2 -négyzet eloszlás $1-\alpha$ kvantilise, elutasítjuk a nullhipotézist.

60. Bayes-tétele

Legyen B_1, B_2, \dots , pozitív valószínűségű
eseményekből álló teljes eseményrendszer,
 $A \in \mathcal{A}$ pozitív valószínűségű. Ekkor

$$P(B_k | A) = \frac{P(A | B_k)P(B_k)}{\sum P(A | B_i)P(B_i)}$$

(Visszakövetkeztetés az első lépés
eredményére.)

Bizonyítás. A nevező éppen $P(A)$ a teljes
valószínűség tétele miatt.

A számláló pedig $P(A \cap B)$, definíció szerint.

61. Adja meg a legkisebb négyzetes becslést a lineáris modellben

A lineáris modell általános alakja:

$$Y = X\beta + \varepsilon,$$

ahol az Y vektor i -edik eleme a függő változó i -edik megfigyelése, az X mátrix i -edik sora a független (magyarázó) változókra vonatkozó i -edik megfigyelés, β becsülendő paraméter, ε nem megfigyelhető véletlen hiba. Legyen Y és X sorainak száma n , X oszlopai száma p . A β legkisebb négyzetes becslése $\hat{\beta} = (X'X)^{-1}X'Y$. A homoszkedasztikus esetben (azaz amikor $\varepsilon = 0$ várható értékű, azonos szórású és korrelálatlan koordinátákból áll) a fenti $\hat{\beta}$ legjobb lineáris torzítatlan becslés.

`[b,bint,r,rint,stats]=regress(Y,X,alfa)` az alábbiakat számolja: **b** a fenti $\hat{\beta}$ becslés (numerikusan a QR dekompozícióval számolva), **bint** β -ra konfidencia intervallum (t-eloszlás alapján számolva), **r** a maradék vektor, **rint** erre konfidencia intervallum. A maradék definíciója: $r = Y - X\hat{\beta}$, ennek alkalmas normalizáltja t-eloszlású, ami alapján a konfidencia intervallum megszerkeszthető. A konfidencia intervallumok szintje: $100(1-\alpha)\%$. A **stats** négy értéket tartalmaz: az R^2 statisztikát (amely a maradék négyzetösszeg és a teljes négyzetösszeg hányadosa, $R^2 \leq 1$, és minél közelebb van 1-hez, annál jobb az illeszkedés), az F statisztikát, annak szignifikancia szintjét és a hiba szórásnégyzetének becslését. A program kódja alapján a fenti F-próba a [konstans + zaj] modellel teszteli az általános modellel szemben. Ha a modell ténylegesen [konstans + zaj] alakú (és X oszlopai között szerepel a konstans), akkor F eloszlása centrált $F(p-1, n-p)$.